

Практическое занятие №4

Реализация нейронной сети Хемминга. Построение WTA-сети на мемристормом кроссбаре.

Введение

Искусственная нейронная сеть обычно использует матрицу весовых коэффициентов для представления множества синапсов слоя нейронов. Соответственно вычисление активации слоя нейронов можно рассматривать как умножение этой матрицы весов на вектор входных сигналов слоя. Аппаратная реализация нейронной сети требует много памяти для хранения матрицы весов слоя нейронов и является дорогостоящей. Решение этой проблемы упрощается при использовании в качестве ячейки памяти устройства, называемого мемристором. Мемристор был предсказан теоретически в 1971 г. Леоном Чуа [1]. Первую физическую реализацию мемристора продемонстрировала в 2008 г. лаборатория фирмы «Hewlett Packard» в виде тонкоплёночной структуры TiO_2 [2]. В России первый мемристор на основе TiO_2 получен в 2012 г. в Тюменском государственном университете [3]. Мемристор имеет много достоинств, таких, как энергонезависимость хранения информации, малое потребление энергии, высокая плотность интеграции и замечательная масштабируемость. Уникальная способность сохранять следы возбуждения устройства делает его идеальным кандидатом для реализации синапсов в электронных нейронных сетях [4].

Мемристор ведет себя подобно синапсу: он «запоминает» полный электрический заряд, прошедший через него [5]. Память, основанная на мемристорах, может достигать очень высокой степени интеграции 100 Гбит/см^2 , в несколько раз более высокой, чем на основе технологии флэш-памяти [6]. Эти уникальные свойства делают мемристор многообещающим устройством для создания массово-параллельных нейроморфных систем [7].

В «аналоговых» мемристорах (например, на основе окиси титана TiO_2) непрерывное изменение напряжения вызывает непрерывное и постепенное (инкрементное) изменение проводимости. Тот же эффект достигается при применении последовательно положительных или отрицательных программирующих импульсов. Сопротивление аналогового мемристора (рис. 1) может быть представлено как

$$M(p) = p \cdot R_{\text{on}} + (1 - p) R_{\text{off}},$$

где p ($0 \leq p \leq 1$) — положение фронта примеси относительно полной толщины h плёнки TiO_2 ; R_{on} и R_{off} — минимальное и максимальное сопротивления мемристора. Когда на мемристор подаётся напряжение V выше некоторого порога V_{th} , его сопротивление уменьшается за счёт расширения примесной зоны D , имеющей низкое сопротивление, и сокращения зоны U чистого окисла, имеющей высокое сопротивление. Соответственно сопротивление мемристора возрастает при подаче напряжения V ниже $-V_{\text{th}}$ за счёт сокращения зоны D и расширения зоны U . После отключения напряжения текущее сопротивление мемристора сохраняется.




Рис. 1. Мемристор

В «цифровых» (бинарных) мемристорах сопротивление изменяется резко (с низкого на высокое и обратно), когда приложено напряжение, «пересекающее» порог. Скачкообразное изменение сопротивления обусловлено образованием проводящего филамента. Например, при образовании Ag-филамента в аморфном кремнии (a-Si, который служит материалом электролита) наблюдается устойчивый эффект резкого изменения сопротивления. Такой мемристор имеет чёткий порог переключения и резкое изменение сопротивления при напряжении считывания 1 В. Время переключения составляет менее 10 нс. Особенно интересны реализации синаптических устройств на окиси гафния HfO_2 , поскольку такая память имеет блестящие характеристики: большая масштабируемость (до размеров менее 10 нм), малое время переключения (порядка 1 нс).

Бинарные мемристоры, основанные на механизме переключения филамента, распространены более широко, чем аналоговые, материалы для которых встречаются значительно реже и требуют более сложного процесса обработки. При переключении филамента мемристоры могут иметь либо высокое сопротивление (ВС), либо низкое (НС). Таким образом, мы можем хранить только 1 или 0 (–1) при переключении филамента бинарного мемристора. Бинарные мемристоры гораздо более устойчивы к статистическим флуктуациям по сравнению с аналоговыми. Это связано с тем, что ВС намного выше, чем НС, несмотря на большое количество флуктуаций в НС и ВС.

На рис. 2 представлен мемристорный кроссбар, который является типичной структурой мемристорной памяти. Он содержит мемристор на каждом пересечении горизонтальных и вертикальных проводников. Мемристорный кроссбар интересен для реализации матриц соединений в нейронных сетях, поскольку он может обеспечить большое число сигнальных связей и вычислить взвешенную комбинацию входных сигналов. На вертикальные шины кроссбара подаются компоненты вектора входных сигналов. Каждая горизонтальная шина позволяет вычислить скалярное произведение вектора входных сигналов на вектор весов, заданных проводимостями мемристоров соответствующей строки кроссбара.




Рис. 2. Кроссбар-массив мемристоров для векторно-матричного умножения (VMM)

Физическая реализация модели мемристора в Electronics Workbench показана на рис. 3.




Рис. 3. Модель мемристора в Electronics Workbench

Сеть Хемминга и её реализация с использованием мемристорного кроссбара

В сети Хемминга нейроны первого слоя рассчитывают расстояния Хемминга между поданным на вход сети вектором x и векторами весов (эталонными векторами) x^i нейронов этого слоя. Расстоянием Хемминга $d(x, y)$ между векторами x и y называется количество несовпадающих компонент этих векторов. Значения выходных сигналов нейронов первого слоя определяются по формуле

$$y_i = 1 - d(x^i, x)/N, \quad (1)$$

где N — число компонент вектора x . Из (1) следует, что $y_i \in [0, 1]$, причём для $x = x^i$ выполняется $y_i = 1$ (максимально возможное значение).

Сигналы y_i становятся начальными состояниями нейронов второго слоя, которые функционируют по принципу WTA («Winner Takes All»). Этот слой определяет победителя среди нейронов первого слоя, т. е. нейрон, выходной сигнал которого наиболее близок к 1. Такой нейрон указывает на эталонный вектор x^i с минимальным расстоянием Хемминга до входного вектора x .

Поставим в однозначное соответствие эталонному вектору сети Хемминга x^i , $i = 1, \dots, p$, вектор весов w^i , задаваемых проводимостями мемристоров кроссбара, по правилу

$$w_j^i = \begin{cases} g_L, & \text{если } x_j^i = -1, \\ g_H, & \text{если } x_j^i = 1, \end{cases}$$

где $g_H > g_L$, $j = 1, \dots, N$. Пусть w — произвольный вектор размерности N с компонентами g_L и g_H .

Утверждение 1. $(x^i, w^i) - (x^i, w) \geq g_H - g_L > 0$, если $w \neq w^i$.

Доказательство. Пусть m компонент вектора w^i равны g_H , а n компонент — g_L , $m + n = N$. Согласно определению вектора x^i , имеем

$$(x^i, w^i) = mg_H - ng_L. \quad (2)$$

Чтобы получить из w^i вектор w , нужно заменить k ($k \in \{1, \dots, m\}$) компонент g_H на g_L и/или l ($l \in \{1, \dots, n\}$) компонент g_L на g_H . Тогда

$$(x^i, w) = (x^i, w^i) + k(g_L - g_H) - l(g_H - g_L). \quad (3)$$

Из (2) и (3) следует $(x^i, w^i) - (x^i, w) = (k + l)(g_H - g_L) \geq g_H - g_L > 0$, так как $g_H > g_L$.

Из утверждения 1 следует, что вычисления по формуле (1) можно заменить на вычисление скалярного произведения (x, w^i) , которое может быть реализовано на мемристорном кроссбаре. Мемристорный кроссбар с указанными выше свойствами не реализует формулу (1) вычислений первого слоя сети Хемминга, но обеспечивает требуемое свойство этого слоя: нейрон с весовым вектором w^i , представленный i -й строкой кроссбара, для эталонного вектора w^i дает максимальный выходной сигнал $y_i = (x^i, w^i)$.

Будем называть вектор w нетривиальным, если хотя бы одна его компонента равна g_H . Тогда $(x^i, w) \geq g_H - (N - 1)g_L$, откуда следует

Утверждение 2. $(x^i, w) > 0$ для нетривиального w , если

$$g_L \leq \frac{g_H}{N - 1}. \quad (4)$$

Неравенство (4) задаёт ограничение на отношение между максимальной g_H и минимальной g_L проводимостями мемристоров кроссбара, которое обеспечивает неотрицательность выходного сигнала нейрона первого слоя сети Хемминга. Предложенный здесь подход к построению ассоциативной памяти Хемминга позволил сократить вдвое количество используемых мемристоров

Пример реализация сети Хемминга

На рис. 4 представлены изображения символов «L», «T», «X» размером 3×3 пикселей. Эти изображения могут быть описаны эталонными векторами (построчная развертка изображений)

$$\begin{aligned} L &= (1, -1, -1, 1, -1, -1, 1, 1, 1), \\ T &= (1, 1, 1, -1, 1, -1, -1, 1, -1), \\ X &= (1, -1, 1, -1, 1, -1, 1, -1, 1), \end{aligned}$$

где 1 соответствует белым пикселям, а -1 — чёрным.




Рис. 4. Изображения символов

Запоминание этих изображений в памяти Хемминга реализовано мемристорным кроссбаром, представленным на рис. 5, где каждая строка соответствует одному из изображений. Компоненте 1 эталонного вектора в кроссбаре соответствует мемристор с минимальным сопротивлением $R_L = 100 \text{ Ом}$ (с максимальной проводимостью $g_H = 1/R_L$), а компоненте -1 — мемристор с максимальным сопротивлением $R_H = 100 \text{ кОм}$ (с минимальной проводимостью $g_L = 1/R_H$). Обозначив векторы весов через w^L , w^T и w^X , можем записать выходные сигналы строк кроссбара (рис. 5):

$$\text{SumL} = (x, w^L), \quad \text{SumT} = (x, w^T), \quad \text{SumX} = (x, w^X),$$

где x — вектор входных сигналов, компоненты которого — напряжения V (соответствует 1) и 0 V (соответствует -1). Модуль напряжений выбран ниже порога бинарного мемристора, чтобы исключить возможность изменения проводимости мемристоров кроссбара при его эксплуатации.

Второй слой сети Хемминга (рис. 5) реализован на основе КМОП-технологии и преобразует вектор входных сигналов по принципу WTA, то есть максимальной входной компоненте он ставит в соответствие 1 на выходе (высокое напряжение, для схемы рис. 6 оно составляет около 5 В), а остальным входным компонентам ставится в соответствие 0 (напряжение, близкое к нулю, для схемы рис. 6 оно составляет около $0,1 \text{ мВ}$). Для примера на рис. 5 выполняется $\text{SumT} > \text{SumL}$ и $\text{SumT} > \text{SumX}$. В этом случае на выходе второго слоя (рис. 6) получаем $\text{OutT} = 1$, $\text{OutL} \approx 0$, $\text{OutX} \approx 0$. Схема памяти Хемминга (рис. 5 и 6) реализована в системе моделирования Electronics Workbench




Рис. 5. Реализация нейронной сети Хемминга в Electronics Workbench

Программная реализация сети Хемминга

На рис. 6. представлена программа (Python), которая является простым примером нейронной сети Хемминга для распознавания символов 3 на 3.

Функция `hamming_distance` (Хеммингово расстояние) принимает два массива и считает количество различий между ними.

Функция `recognize_symbol` (Распознавание символа) принимает на вход 3x3 матрицу и сравнивает её с известными символами, используя Хеммингово расстояние. Минимальное расстояние указывает на распознанный символ.

Используется `matplotlib` для отображения распознаваемого символа (в качестве визуализации).

Python ▾



```
1 import numpy as np # Импортируем библиотеку numpy для работы с массивами
2 import matplotlib.pyplot as plt # Импортируем matplotlib для визуализации данных
3
4 # Создание обучающего набора данных с символами
5 symbols = {
6     'L': np.array([[1, 0, 0], # Определяем символ 'L' как 3x3 массив
7                    [1, 0, 0], # Вторая строка
8                    [1, 1, 1]]), # Третья строка
9     'T': np.array([[1, 1, 1], # Определяем символ 'T'
10                   [0, 1, 0], # Вторая строка
11                   [0, 1, 0]]), # Третья строка
12     'X': np.array([[1, 0, 1], # Определяем символ 'X'
13                   [0, 1, 0], # Вторая строка
14                   [1, 0, 1]]) # Третья строка
15 }
16
17 # Функция для вычисления Хеммингового расстояния
18 def hamming_distance(a, b):
19     return np.sum(a != b) # Считаем количество различий между массивами a и b
20
21 # Функция для распознавания символа
22 def recognize_symbol(input_symbol):
23     distances = {} # Создаем словарь для хранения расстояний до известных символов
24     for symbol, template in symbols.items(): # Проходим по всем известным символам
25         distances[symbol] = hamming_distance(input_symbol, template) # Вычисляем расстояние
26
27     # Находим символ с минимальным расстоянием
28     recognized_symbol = min(distances, key=distances.get) # Находим символ с наименьшим расстоянием
29     return recognized_symbol # Возвращаем распознанный символ
30
31 # Пример использования
32 input_symbol = np.array([[0, 0, 0], # Входной символ для распознавания
33                          [1, 0, 0],
34                          [1, 1, 0]])
35
36 recognized = recognize_symbol(input_symbol) # Вызываем функцию распознавания
37 print(f'Распознанный символ: {recognized}') # Выводим распознанный символ
38
39 # Визуализация
40 fig, ax = plt.subplots() # Создаем фигуру и оси для графика
41 ax.imshow(input_symbol, cmap='gray', vmin=0, vmax=1) # Отображаем входной символ с цветовой картой
42 ax.set_title('Входной символ') # Устанавливаем заголовок для графика
43 plt.show() # Показываем график
```

Рис. 6. Реализация нейронной сети Хемминга на Python




Рис. 7. Результат выполнения программы с распознанным символом

Заключение

Предложена аппаратная реализация ассоциативной памяти Хемминга на основе использования кроссбара на бинарных мемристорах и КМОП-схемотехники. Показано, что кроссбар на бинарных мемристорах, где максимальное сопротивление мемристора соответствует значению -1 компоненты хранимого эталонного вектора, а минимальное — значению $+1$, реализует свойства первого слоя сети Хемминга, согласно которым выходной сигнал нейрона первого слоя неотрицателен, причём он максимален для нейрона, эталонный вектор которого наиболее близок к входному. Для заданной размерности эталонного вектора получено соотношение между максимальным и минимальным сопротивлениями бинарных мемристоров, которое гарантирует корректную работу первого слоя сети Хемминга.

Содержание работы.

Ответьте на вопросы и выполните следующие задания:

1. Перечислите особенности нейронной сети Хемминга.
2. Приведите математическую модель нейронной сети Хемминга.
3. Проведите исследование модели мемристора в Electronics Workbench.
4. Привести программный код на Python реализации нейронной сети Хемминга для распознавания символов размерностью 3×3 .
5. Осуществите реализацию нейронной сети Хемминга для распознавания символов размерностью 3×3 средствами Electronics Workbench. Проанализируйте полученные результаты.